

青少年大脑发育建模：传统脑图谱与深度生成模型的研究进展与挑战

1. 传统神经影像学 Brain Chart 研究的贡献与局限

贡献：“Brain Chart”代表了一种建立大脑发育标准曲线的努力，为青少年（尤其9-15岁）脑结构发育提供了大规模的规范性基线¹。这项研究汇聚了全球超过10万名受试者的123,984份MRI扫描数据，覆盖从胚胎期到100岁的广泛年龄范围¹。通过对诸如**皮层厚度**、**皮层表面积**、**皮层体积**等单一形态学指标建立百分位曲线，它提供了类似儿科生长曲线的参考，用于衡量个体大脑结构相对于人群发育轨迹的偏离程度^{2 3}。Brain Chart工作报告了此前未知的神经发育里程碑事件，并显示出个体在纵向随访中的排名高度稳定⁴。这些贡献表明，Brain Chart是定量评估大脑结构随年龄变化及个体差异的重要里程碑，为精神疾病和神经发育异常的研究提供了“正常”轨迹参照⁵。

局限：尽管Brain Chart提供了有价值的规范性轨迹，但其存在重要局限：首先，它主要针对**单一变量**进行分析。例如，研究通常分别绘制皮层厚度、表面积或体积的曲线，而**缺乏不同脑特征间关联的综合建模**。这种**单变量视角**无法揭示脑结构不同方面之间的复杂相互作用，以及多维度特征协同发育的模式。其次，Brain Chart给出的主要**群体平均轨迹**（如年龄对应的中位数曲线及其百分位范围），只能反映总体趋势³。这意味着其输出是**规范化的均值路径**，**不直接提供具体个体的发育轨迹**——个体只能通过比较自身测量值所在的百分位来定位相对于人群的发育水平³。因此，该方法无法刻画个体独特的发育动力学，也难以预测偏离均值的发展模式。另外，Brain Chart主要基于横断面数据拟合非线性轨迹，这可能**低估真实的纵向变化**⁶。一项研究比较了基于横断面推断的脑发育曲线与真实纵向数据，发现横断面“脑图谱”往往**低估了个体纵向随访中观察到的变化幅度**⁶。这强调了单纯群体模型的局限：**无法充分捕捉个人随时间的发育动态和差异**。总之，Brain Chart虽为大规模**规范性建模**迈出了关键一步，但由于**聚焦单变量且以群体平均轨迹为核心**，在揭示多维脑特征联动变化和个体特异性发育模式方面存在不足。

2. 深度学习脑网络生成模型的主流方法及局限性

针对脑连接组(connectome)的深度生成模型（如基于**变分自编码器**VAE、**图神经网络**GNN、**扩散模型**Diffusion Models等）正日益受到关注。然而，这些模型在以下方面存在明显局限：

- (1) **拓扑结构生成的准确性不足：**许多深度生成模型虽然能够复现脑网络的一般统计属性，但无法**精确保留真实脑网络的拓扑/同调特征**。研究发现，传统**生成网络模型**常能模拟大脑网络的某些拓扑指标（如度分布、小世界性等），但**未能捕捉关键的空间拓扑结构**，例如**长程连接**的解剖布局和脑区枢纽的位置⁷。Oldham等人(2025)的研究表明，现有生成模型无法准确再现大脑网络中长程跨区连接的空间分布，导致生成网络中枢纽位置与真实大脑不符⁷。标准评估指标可能掩盖了合成网络与真实网络在这些方面的差异，使模型性能被高估⁷。此外，典型的深度生成模型(GAN、VAE等)往往**只关注逐边的重构误差**，缺乏对全局拓扑属性的约束，可能破坏脑网络的高阶特征（如模块结构或循环同调性）。近期有学者专门引入**拓扑损失函数**，以缩小生成网络与真实网络在同调特征上的差距⁸。例如，一项方法通过“脑扩散损失”优化生成网络，使其产生的连通矩阵更贴近真实拓扑，显著减少了生成网络与真实网络在拓扑形态上的差异^{8 9}。总体而言，**现有模型对脑网络拓扑结构的刻画精度有限**，复杂的同调特征（如环路、团簇结构等）可能未被充分保留。
- (2) **个体差异的建模能力有限：**深度生成模型通常基于**群体数据**学习脑网络分布，**难以针对个体特征生成定制化的网络**。现实中“没有两个个体的连接组是完全相同的”，不同个体的脑网络差异与其行为、基因等因素息息相关¹⁰。然而许多生成模型**未显式纳入个体属性**（如年龄、性别、遗传因素），

生成样本主要反映总体分布而非某一特定个体。这导致模型往往生成“平均化”的脑网络，难以覆盖真实个体的多样性和极端情况¹⁰。在传统组间比较范式中，不同个体间发育异质性经常被淹没于组平均差异中，结果可能互相矛盾或缺乏明确结论¹⁰。类似地，生成模型若不考虑个体因素，其输出也缺乏针对个人的精细刻画。这对精确建模青少年发育中的个体差异尤为不利，因为青春期大脑发育存在显著的个体节律和速度差异（例如青春期启动时间、环境影响等）。近期有学者提出结合规范化建模与深度生成的方法，以个人属性为条件生成个性化连接组^{11 12}。例如，有研究利用个体的人口学和临床信息，生成个性化连接组以捕捉每个人特有的网络特征（该工作已在Medical Image Analysis发表，2025）。尽管取得进展，总体来说当前主流模型对个体特异性的刻画仍显不足，需要引入更多条件生成或个性化嵌入机制以更好地模拟每个人独特的大脑网络。

- (3) 时序发育过程的表达能力不足：大多数深度生成模型将脑网络视为静态样本来建模，忽略了大脑随时间发育的动态演变¹³。青少年时期脑网络结构和功能都会发生剧烈的变化，静态模型无法表达这种随年龄增长的重组过程。例如，以往许多研究使用单一时间点的连接矩阵训练生成模型，而未考虑童年到青春期各阶段网络拓扑的持续改变¹³。这导致模型无法生成反映发育阶段的信息，也难以回答“网络如何从儿童形态发展到青少年形态”这样的关键问题。一项最新研究（Campbell等，2023）开发了动态脑图深度生成模型（DBGDGM），通过引入时间演化因子同时学习社群结构的随时间演进和节点嵌入的动态变化¹³。该模型强调，不考虑时间信息的静态方法会遗漏大脑发育的重要维度¹³。因此，目前主流生成模型在发育时序建模上依然薄弱，难以捕捉青少年脑网络随时间的重组轨迹，需要发展显式时间建模或纵向数据训练的模型来提升对时序发育过程的表达能力。
- (4) 泛化能力与数据依赖问题：深度模型通常需要大量多样的数据以概括真实分布，但脑连接组数据规模有限且异质性高，这给模型的泛化带来挑战。许多脑网络生成模型在相对小规模或单一来源的数据上训练，可能存在过拟合，在新数据集或不同人群上表现不佳¹⁴。MRI采集方案、分辨率、种族与环境因素的差异，都可能导致模型跨数据集泛化性能下降。例如，有研究指出，用单一研究的有限样本拟合的发育轨迹泛化能力很弱¹⁴。只有汇聚大样本、多中心的数据才能提高模型的普适性¹⁴。当前很多生成模型缺乏跨站点的验证，其在不同队列上的稳健性未知。此外，由于脑网络数据高维且噪声较大，模型容易学习到数据中偶然相关的模式，从而在新数据上失灵。因此，泛化性不足是深度生成模型在实际应用中面临的重要问题，需要通过正则化、域自适应、更大规模训练等手段加以改进。
- (5) 模型可解释性与透明度欠缺：深度学习模型往往被视为“黑箱”，脑网络生成模型也不例外，其内部机理和决策依据难以理解¹⁵。在脑科学和临床应用中，理解模型为何生成某种网络、该网络的哪部分结构对应特定特征，是非常重要却缺乏解答的问题¹⁵。目前许多基于图神经网络的脑网络模型在输出疾病预测或生成脑网络时，无法明确指示哪些脑区或连接主导了模型决策¹⁵。这种可解释性缺失限制了模型在科研和临床中的信任度和应用¹⁵。举例来说，一个模型生成一组青少年脑结构连接，但我们难以解释其依据的生物学模式，也无法确定它是否捕捉到已知的关键发育网络特征。为提升可解释性，近期有研究提出在模型中集成注意力机制或显著性提取模块，以标记对结果贡献最大的节点和边¹⁶。例如，Cui等人提出了一个可解释图神经网络框架，包括用于疾病预测的主模型和一个全局解释生成器，能够高亮显示疾病相关的ROI脑区和重要连接，识别出有生物学意义的网络生物标记¹⁶。又如，“BrainGNN”通过设计区域池化层，自适应选取对任务最有贡献的一 subset脑区，从而实现一定程度的可解释性，发现与神经疾病相关的关键脑区子图¹⁷。总的来说，当前模型的可解释性问题仍未解决，迫切需要发展可解释的深度生成模型，通过引入可视化工具或可解释模块来阐明模型决策，与神经生物学知识建立联系。

3. 脑结构形态学变量与结构连接的关联及其建模价值

形态学变量与结构连接的生物学关联：青少年时期，大脑结构形态（如皮层厚度、皮层体积、髓鞘发育等）与其结构连接（白质纤维连接）呈现出密切的相互关系。在发育过程中，皮层变薄（cortical thinning）是青少年脑成熟的显著标志，而研究表明这种皮层减薄模式受到白质结构网络架构的限制和影响¹⁸。一项针对儿童到青春期的研究发现，皮层减薄主要发生在额顶异模态联络区，这些区域的减薄模式可以用其在大脑白质连接网络中的地位来解释：它们处于网络中高连接的枢纽位置，受到更强的结构网络约束^{18 19}。也就是说，白质结

构连接组为灰质的形态变化提供了结构支架：哪片皮层区域会更显著地变薄，和该区域在结构网络中的连接模式密切相关¹⁹。此外，在神经发育的细胞层面，皮层形态变化（如厚度减小）与神经元突触修剪和轴突髓鞘化等过程并存²⁰。这些过程并非孤立发生：早期建立的白质通路在发育中起到“沟通各因素的骨架”作用，协调着局部的突触重塑和髓鞘沉积²⁰。例如，轴突张力学说认为，连接不同脑区的白质纤维对这些区域施加“拉力”，影响皮层的折叠与厚度²⁰。确有研究支持这一点：白质纤维在儿童期就定位好大体走向，随后皮层会沿着这些“应力线”发生形态调整，如同步的突触修剪（导致变薄）和轴突髓鞘化²⁰。值得注意的是，髓鞘化程度与皮层厚度之间也存在负相关关系：青春期联络皮层区域髓鞘增加通常伴随该区域皮层变薄²¹。例如，有遗传学研究发现，在青少年中大脑髓鞘增加和联络皮层变薄是相关联的，并可能共享部分遗传基础²¹。这些证据都表明：脑结构连接和形态学发育并非彼此独立，而是通过解剖连接和分子机制相互影响、协调发展的。

在青少年发育建模中的作用与价值：将形态学指标与结构连接结合起来进行建模，有望更全面地表征青少年大脑发育过程，并提升对个体发育状态的预测能力。单纯依赖形态学变化（如只看皮层厚度）可能无法解释为何某些区域变化更剧烈、如何各区域变化步调相关；引入结构连接信息可以提供因果或机制线索。例如，基于结构连接的扩散模型成功解释了为何额顶联络皮层在青春期显著变薄：因为这些区域在结构网络中连接丰富、传导了更多“成熟信号”或受白质牵引影响更大^{22 20}。因此，一个将皮层厚度和结构连接强度联合建模的系统，可以捕获“如果两个区域高度连接，则它们可能经历协同的形态改变”这一模式。这对于识别异常发育也很有价值：如果某个青少年个体的某些脑区形态改变没有遵循其结构连接所预示的模式，可能提示异常。实际上，结构连接与形态的协变已被用来构建结构协方差网络，发现这些网络与实际解剖连接高度相关²³。从建模角度看，将形态和连接特征结合能提高对发育阶段的判别。例如，有研究将皮层厚度、体积等形态指标与白质连接特征一起纳入机器学习模型，结果显著提升了对年龄的预测精度和对个体脑成熟程度的评估。这说明形态和连接提供了互补的信息：形态学度量体现局部组织的发育程度，结构连接则反映全脑整合程度和网络成熟度。特别是在青春期，大脑结构连接不断加强（髓鞘化使传导效率提高），同时灰质体积和厚度减小，这是大脑由“儿童模式”转向“成年模式”的体现。两者结合建模，可以捕获这一此消彼长的规律，从而更好地解释发育过程的生物学机制。总之，融合脑结构形态学与结构连接的模型有潜力更准确地模拟青少年大脑发育，并帮助识别偏离正常轨迹的异常模式，为脑发育研究和青少年精神卫生提供有力工具。

4. 补充调研主题

4.1 功能连接在青少年发育中的作用及与结构连接的互补性

功能连接在发育中的关键作用：大脑的功能连接（Functional Connectivity, FC）指不同脑区间活动同步性或相关的模式，它在青少年认知和行为能力的发展中扮演关键角色。儿童进入青春期，大脑功能网络经历大规模的重组：局部功能网络更加分化（各自执行专业功能），同时全脑网络之间的整合增强，以支持更复杂的认知过程^{24 25}。研究表明，在晚期童年到青春中期，大脑结构-功能耦合（即结构连接与功能连接的关联程度）显著提高^{24 25}。例如，默认模式网络、注意控制网络等高级功能系统在青春期功能连接强度增加，并与白质结构成熟相伴随，从而提升了大脑各区域协同工作的效率^{26 27}。功能连接的发展也与认知能力直接相关：功能网络的成熟（如前额叶和其他区域的连接增强）被认为支撑了青少年执行功能和自我调控能力的提高。此外，功能连接的异常常可预测发育中的问题，例如多动症（ADHD）、自闭症等患者在青春期表现出与正常发育不同的功能连接模式。综上，功能连接动态反映了青春期大脑神经通讯和网络组织的变化，是理解大脑发育功能转变的关键窗口。

功能连接与结构连接的互补性：功能连接和结构连接分别代表大脑网络的“通信流”与“有线架构”，两者在发育研究中具有明显的互补特性^{28 29}。首先，结构连接（白质纤维）构成了大脑可能的通信路径，它为功能连接提供了解剖基础：如果两个区域间没有解剖连接，持续的同步活动通常难以维持²⁹。因此，结构连接将脑网络的物理可能性限定在一定范围内。而功能连接反映了实际信息交换，可以在结构连接支持下发生，也可以通过多跳路径或中介节点间接发生²⁹。在青春期，结构与功能的耦合度逐渐增加，表明功能网络越来越依赖底层结构架构来组织^{24 29}。然而，两者并非一一对应：功能连接具有更大的可塑性和瞬时性，能根据环境需求和学习经验迅速改变，而结构连接改变相对缓慢。正因如此，在发育过程中，经常观察到功能网络的重组领先于或大于结构网络的改变。功能连接可以揭示结构连接无法捕获的动态，例如短期的网络节点参与度变

化、任务状态下的网络重构等。举例来说，在青春期的大脑中，即使某些结构连接尚未完全髓鞘化，功能上已经可以通过现有回路实现新的协作，这体现为功能连接的提前变化。此外，一些长程功能连接的变化可能预示着即将发生的结构重塑。研究发现，在青少年中，各脑网络内的功能连接随白质成熟呈现更强的分离（网络内部高度连接、网络之间相对隔离），这种变化与白质连接的选择性强化相辅相成³⁰。简而言之，将功能连接与结构连接结合分析可以更完整地描绘大脑发育：结构连接揭示潜在线路图，功能连接展现实时交通流。两者的差异提供了重要的生物学信息：例如，如果某对脑区结构上高度连接但功能连接弱，可能表明该通路尚未成熟或被某种机制抑制；反之，功能连接强于解剖连接预期，可能意味着存在间接通路或动态偶联现象。这种互补视角已被用于评估青少年脑发育健康，例如结构-功能耦合度被作为衡量指标，评估一个人脑网络发育是否达到同期应有水平²⁹。综上，功能连接在青少年发育研究中具有不可或缺的作用，与结构连接相结合能够更好地解释大脑功能完善的机制，也有助于识别异常发育（结构正常但功能异常，或反之）的情况，为综合理解脑发育提供完整图景。

4.2 脑图谱发育建模中的GNN可解释性问题及改进方向

GNN模型的可解释性挑战：图神经网络（Graph Neural Network, GNN）因能够直接处理脑连接图数据而广受青睐，但其“黑箱”性质引发了重大可解释性挑战¹⁵。在脑图谱发育建模中，我们希望知道哪些脑区或连接驱动了模型的预测，例如哪些特定边的变化指示大脑成熟。然而，标准GNN难以提供这种直观解释：模型将高维连接数据嵌入到隐层表示，最终输出预测（如发育年龄、疾病风险），中间过程对人类来说晦涩难懂¹⁵。对于研究者和临床医生而言，这种不透明性降低了对模型的信任，也限制了模型用于发现新的生物学知识。例如，一个GNN模型预测某青少年大脑发育落后同龄，但我们无法从模型中直接看出是哪个子网络的发育异常导致的。这种缺乏解释的情况在注重机制的脑科学领域尤其令人担忧¹⁵。此外，GNN模型往往有成千上万个参数，容易过拟合小样本脑网络数据³¹，模型可能利用了数据集中某些特定相关性而非普遍生物学模式，进一步加剧了结果解释的复杂性³²。因此，提升GNN在脑图谱发育研究中的透明度是当务之急。

潜在改进方向：为增强GNN模型的可解释性，研究者正探索多种策略：1. **内置可解释模块：**在模型结构中加入专门用于解释的组件。例如设计注意力机制或门控单元，使模型在聚合邻居信息时学习注意权重，从而刻画每条连接对输出的重要性。如果某些连接在注意力中权重突出，可视为模型认为这些连接对发育预测“重要”。类似地，**节点/子图选择模块**（如可学习的池化层）可以让模型在若干轮迭代后选出最能代表全图的若干节点或子图¹⁷。在BrainGNN框架中，就通过**可学习的池化**来突出关键脑区子图，从而识别与认知相关的网络结构¹⁷。这类方法把解释融入模型训练，产生的注意权重或选中子图即为直接的解释。2. **后验解释技术：**即对训练完毕的GNN应用**解释算法**。例如，**GNNExplainer**等方法通过优化找到能最大程度影响模型输出的一个子网络，从而解释模型决策。具体来说，它尝试为某个预测寻找一个最小的节点-边子集，使得仅用该子集输入模型仍能保持原有预测结果。这样的子集被视为模型关注的**判别特征子网络**。在发育建模中，这可能对应某几个脑区及其相互连接的发育情况。还有方法基于**特征归因**（如计算每条边对预测结果的梯度），得到每条连接的贡献分数，再选出高分者作为重要连接。这些后验方法不需改变模型，但需要额外计算，解释结果可能不唯一，但为理解模型提供了可参考的信息。3. **引入先验和约束：**在模型训练时融入**生物学先验**，引导模型学习可解释的模式。例如，要求模型的隐藏表示与已知的功能网络划分相关，对同一已知功能网络内的节点施加相似约束，使模型更容易被解读为传统网络成分。或者在损失函数中增加项，鼓励模型的预测与某些**可解释的指标**（如全脑效率、模块度）相关联，从而部分恢复生物学意义。此外，利用多任务学习，让模型同时预测几个与发育相关的生理指标（如激素水平、认知测验分数），可以迫使模型关注那些既影响脑连接又影响这些指标的关键特征，提高解释的生理相关性。4. **模型简单化与可视化：**一些情况下，可选择较简单的GNN变体（如线性GNN或少层GNN），牺牲一定性能换取可解释性。例如线性GNN的参数可以直接解释为节点特征的线性组合权重，更易理解其作用。另外，将高维GNN嵌入输出与真实数据进行相关分析或可视化（如主成分分析），查看其主要变化方向是否对应已知发育模式，也是检验模型合理性的方法。

当前已有探索证明可解释性改进的有效性。例如，**可解释GNN框架IBGNN**通过在模型中集成信息瓶颈和解释生成器，实现了对脑连接图分类决策的可解释分析，能够定位特定脑区和连边作为生物标志物¹⁶。总的来看，提高GNN在脑发育建模中的可解释性需要**模型设计与后处理结合**：既要开发内生具有透明度的模型架构，又要运用解释算法挖掘黑箱模型中的意义模式。随着这些改进方向的推进，我们有望构建出既**性能优秀**又**易于理解**的图神经网络模型，用于揭示青少年大脑发育的复杂网络机制。

参考文献：

1. Bethlehem, R. A. I., 等. Brain charts for the human lifespan. **Nature**, 604(7906):525–533 (2022) 2
3
2. Dong, T., 等. Mapping human brain charts cross-sectionally and longitudinally. **PNAS**, 120(32): e2218995120 (2023) 6
3. Oldham, S., & Fornito, A. Generative network models fail to capture long-range connectivity. **Network Neuroscience** (MIT Press), 9(4):1001–1021 (2025) 7
4. Wei, J., 等. ConnectomeDiffuser: Generative AI enables brain network construction from diffusion MRI. **arXiv preprint arXiv:2505.22683** (2023) 9
8
5. Campbell, A., 等. DBGDGM: Dynamic brain graph deep generative model. **MIDL 2023 Conference (Full paper)** 13
6. Shen, R. S., 等. BRIDGE: Individualized deep generative embedding for developmental neurodivergence. **arXiv preprint arXiv:2410.11064** (2023) 10
12
7. Liang, X., 等. Structural connectome architecture shapes the maturation of cortical morphology from childhood to adolescence. **Nat. Commun.**, 15:784 (2024) 18
20
8. Perrone, A., 等. The genetics of cortical myelination in young adults and its associations with cortical thickness. **Sci. Adv.**, 6(44): eaaz6310 (2020) 21
9. Soman, S. M., 等. Cortical structural and functional coupling during development and implications for ADHD. **Transl. Psychiatry**, 13:252 (2023) 24
29
10. Cui, H., 等. Interpretable Graph Neural Networks for connectome-based brain disorder analysis. **MICCAI 2022, Lecture Notes in Computer Science** 13433:3–13 (2022) 33
11. Zhou, S., 等. Graph Neural Networks in Brain Connectivity Studies: a review. **IEEE JBHI**, 27(4): 1821–1832 (2023) 15
12. Li, K., 等. BrainGNN: Interpretable Brain Graph Neural Network for fMRI Analysis. **Pattern Recognition** 122:108155 (2022) 17

1 2 3 4 5 14 Brain charts for the human lifespan | Nature
https://www.nature.com/articles/s41586-022-04554-y?error=cookies_not_supported&code=652997f8-123d-48a4-ba1b-09f39e194e0f

6 Mapping human brain charts cross-sectionally and longitudinally
<https://www.pnas.org/doi/10.1073/pnas.2216798120>

7 Coming up short: Generative network models fail to accurately capture long-range connectivity - PMC
<https://pmc.ncbi.nlm.nih.gov/articles/PMC12635836/>

8 9 ConnectomeDiffuser: Generative AI Enables Brain Network Construction from Diffusion Tensor Imaging

<https://arxiv.org/pdf/2505.22683>

10 11 12 Parsing altered brain connectivity in neurodevelopmental disorders by integrating graph-based normative modeling and deep generative networks

<https://arxiv.org/html/2410.11064v2>

13 proceedings.mlr.press

<https://proceedings.mlr.press/v227/campbell24b/campbell24b.pdf>

15 Graph Neural Networks in Brain Connectivity Studies

<https://pmc.ncbi.nlm.nih.gov/articles/PMC11763835/>

16 33 [2207.00813] Interpretable Graph Neural Networks for Connectome-Based Brain Disorder Analysis

<https://arxiv.org/abs/2207.00813>

17 BrainGNN: Interpretable Brain Graph Neural Network for fMRI Analysis

<https://www.sciencedirect.com/science/article/abs/pii/S1361841521002784>

18 19 20 22 23 Structural connectome architecture shapes the maturation of cortical morphology from childhood to adolescence | Nature Communications

https://www.nature.com/articles/s41467-024-44863-6?error=cookies_not_supported&code=2c735454-5ca3-44e3-bee5-98af210e4319

21 The Genetics of Cortical Myelination in Young Adults and its ...

<https://pmc.ncbi.nlm.nih.gov/articles/PMC7871660/>

24 25 26 27 28 29 Cortical structural and functional coupling during development and implications for attention deficit hyperactivity disorder | Translational Psychiatry

https://www.nature.com/articles/s41398-023-02546-8?error=cookies_not_supported&code=2e4fc806-29c6-47d4-8087-346afdc6622c

30 Structure-function coupling in network connectivity and associations ...

<https://www.sciencedirect.com/science/article/abs/pii/S2950004424000488>

31 A Lightweight, End-to-End Explainable, and Generalized attention ...

<https://www.medrxiv.org/content/10.1101/2024.07.17.24310610v1.full-text>

32 [PDF] Interpretable Graph Neural Networks for Connectome-Based Brain ...

<https://hejiecui.com/files/slides/miccai22.pdf>